

การพยากรณ์การเติบโตของรถยนต์ไฟฟ้าด้วย
เทคนิคการเรียนรู้ของเครื่อง
A Forecasting the Growth of Electric Vehicle Using
Machine Learning

นิตกาล โสสุด¹, มนัสนันท์ เมืองจันทร์¹, แพรวรา ริโยธา¹, อธิยาพร รักอยู่ประเสริฐ¹
และ อนูปงศ์ สุขประเสริฐ^{2*}

¹สาขารัฐกิจดิจิทัลและระบบสารสนเทศ คณะการบัญชีและการจัดการ มหาวิทยาลัยมหาสารคาม

²อาจารย์ประจำคณะการบัญชีและการจัดการ มหาวิทยาลัยมหาสารคาม

Emails: 66010916016@msu.ac.th, 66010916018@msu.ac.th, 66010916042@msu.ac.th, 66010916052@msu.ac.th,
anupong.s@acc.msu.ac.th*

บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์พัฒนาแบบจำลองการพยากรณ์การเติบโตของรถยนต์ไฟฟ้าในประเทศไทยโดยใช้เทคนิคการเรียนรู้ของเครื่อง 3 วิธีที่ใช้ในการวิจัย ได้แก่ การถดถอยเชิงเส้น (Linear Regression) โครงข่ายประสาทเทียม (Neural Network) และการเรียนรู้เชิงลึก (Deep Learning) ข้อมูลประกอบด้วยตัวแปรเศรษฐกิจและสังคมรายเดือนระหว่างปี พ.ศ. 2563 ถึง 2567 จำนวน 60 เดือน รวมถึงจำนวนจดทะเบียนรถยนต์ไฟฟ้าจากกรมการขนส่งทางบกและข้อมูลจากหน่วยงานรัฐ จากนั้นทำการทดสอบประสิทธิภาพในการประเมินด้วย รากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง, ค่าเฉลี่ยผิดพลาดกำลังสอง, ค่าความคลาดเคลื่อนแบบสัมบูรณ์, ค่าความคลาดเคลื่อนยกกำลังสอง และ สัมประสิทธิ์การตัดสินใจพหุคูณ ผลการวิเคราะห์พบว่า โครงข่ายประสาทเทียมให้ความแม่นยำโดยรวมดีกว่าวิธีอื่น โดยสัมประสิทธิ์การตัดสินใจเท่ากับ 86.00% ซึ่งผลการศึกษการพยากรณ์การเติบโตของรถยนต์ไฟฟ้าในประเทศไทยสามารถสนับสนุนการกำหนดนโยบายและการวางแผนโครงสร้างพื้นฐานสถานีชาร์จไฟฟ้า รวมถึงมาตรการสนับสนุนจากภาครัฐและเอกชน โดยการคาดการณ์แนวโน้มในอนาคตช่วยให้การขยายโครงสร้างพื้นฐานและการออกนโยบายมี

ความแม่นยำ ตรงตามความต้องการจริง และสามารถส่งเสริมการใช้พลังงานสะอาดได้อย่างมีประสิทธิภาพ

คำสำคัญ -- การเติบโตของรถยนต์ไฟฟ้า, การพยากรณ์, การเรียนรู้ของเครื่อง, การวางแผนเชิงกลยุทธ์

ABSTRACT

This research aims to develop a forecasting model for the growth of Electric Vehicles (EVs) in Thailand utilizing machine learning techniques. Three distinct methods were employed in this study: Linear Regression, Neural Networks, and Deep Learning. The dataset comprises 60 months of socio-economic variables collected between 2020 and 2024, incorporating EV registration statistics from the Department of Land Transport and data from relevant government agencies. Model performance was evaluated using Root Mean Squared Error (RMSE), Mean Squared Error (MSE), Mean Absolute Error (MAE), Sum of Squared Errors (SSE), and the Coefficient of Determination (R^2). The analysis revealed that the

Neural Network model yielded the highest overall accuracy compared to other methods, achieving a Coefficient of Determination (R^2) of 86.00%. The findings from this study provide significant implications for policy formulation and infrastructure planning, particularly regarding the expansion of EV charging stations and support measures from both public and private sectors. By accurately forecasting future trends, stakeholders can ensure that infrastructure development and policy implementation align with actual demand, thereby effectively promoting the adoption of clean energy.

Keywords — Electric Vehicle Growth, Forecasting, Machine Learning, Strategic Planning

1. บทนำ

ท่ามกลางกระแสการเปลี่ยนแปลงเชิงโครงสร้างของอุตสาหกรรมยานยนต์โลก ประเทศไทยกำลังมุ่งหน้าสู่การเปลี่ยนผ่านจากการใช้เชื้อเพลิงฟอสซิลไปสู่พลังงานไฟฟ้าอย่างเต็มรูปแบบ ภายใต้การขับเคลื่อนนโยบาย “ประเทศไทย 4.0” และแผนพัฒนาพลังงานแห่งชาติ พ.ศ. 2566 ถึง 2580 ที่มีเป้าหมายเชิงยุทธศาสตร์ในการยกระดับประเทศสู่การเป็นฐานการผลิตยานยนต์ไฟฟ้าชั้นนำของภูมิภาคอาเซียนภายในปี 2573 จากกรมการขนส่งทางบก [1] บ่งชี้ถึงอัตราเร่งของการยอมรับเทคโนโลยีนี้เป็นอย่างมีนัยสำคัญ โดยสถิติการจดทะเบียนรถยนต์ไฟฟ้า (Electric Vehicle: EV) มีการเติบโตแบบก้าวกระโดดจากประมาณ 9,700 คันในปี 2564 สู่ระดับกว่า 80,000 คันในปี 2567 ซึ่งสะท้อนถึงพฤติกรรมผู้บริโภคที่ตอบสนองต่อเทคโนโลยีใหม่อย่างรวดเร็ว [2] ปรากฏการณ์ดังกล่าวขับเคลื่อนด้วยปัจจัยที่ส่งผลต่อการเติบโตของการใช้รถยนต์ไฟฟ้าในประเทศมีความหลากหลาย ทั้งความผันผวนของราคาพลังงานในตลาดโลก การขยายตัวของโครงสร้างพื้นฐานสถานีอัดประจุไฟฟ้า และมาตรการกระตุ้นเศรษฐกิจผ่านโครงการ “EV 3.0” และ “EV 3.5” ของภาครัฐ รวมถึงกระแสความตระหนักรู้ด้านสิ่งแวดล้อม [3] การทำความเข้าใจปัจจัยเหล่านี้เพื่อพยากรณ์แนวโน้มการเติบโตของรถยนต์ไฟฟ้าในอนาคตจึงมีความสำคัญต่อการ

วางแผนเชิงกลยุทธ์ของทั้งภาครัฐและภาคธุรกิจ และการกำหนดนโยบายพลังงานสะอาดของประเทศ [4] เพื่อวิเคราะห์การเติบโตของตลาดรถยนต์ไฟฟ้าในปัจจุบันมีความแม่นยำและสามารถรองรับความซับซ้อนของข้อมูลอนุกรมเวลาได้ การศึกษาครั้งนี้จึงเลือกประยุกต์ใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) ซึ่งได้รับการยอมรับในประสิทธิภาพการจัดการข้อมูลขนาดใหญ่และการตรวจจับรูปแบบความสัมพันธ์ที่ไม่เป็นเชิงเส้น [5] โดยมุ่งเน้นการเปรียบเทียบประสิทธิภาพของ 3 เทคนิคหลัก ได้แก่ การถดถอยเชิงเส้น, โครงข่ายประสาทเทียม และการเรียนรู้เชิงลึก ในการพยากรณ์แนวโน้มการเติบโตของรถยนต์ไฟฟ้า โดยใช้ข้อมูลย้อนหลัง 5 ปีจากกรมการขนส่งทางบกและข้อมูลทางเศรษฐกิจ เช่น ราคาน้ำมัน ค่าไฟฟ้าเฉลี่ย ดัชนีความเชื่อมั่นผู้บริโภค และจำนวนประชากร ซึ่งเป็นการเลือกใช้ตัวแปรจำนวนการเกิดของประชากรไทย สอดคล้องกับการศึกษาปัจจัยมหภาคที่มีผลต่ออุปสงค์ยานยนต์ไฟฟ้า โดยอ้างอิงจากงานวิจัย ที่พบว่า การเปลี่ยนแปลงของจำนวนและโครงสร้างประชากรมีความสัมพันธ์อย่างมีนัยสำคัญต่อการเติบโตของตลาดรถยนต์ไฟฟ้า รวมถึงตัวแปรทั้งหมดที่ได้รับการพิสูจน์แล้วว่า มีอิทธิพลต่อการเปลี่ยนแปลงของตลาด [4,6]

การศึกษานี้ดำเนินการตามกระบวนการมาตรฐานในการทำเหมืองข้อมูล (Data Mining) โดยให้ความสำคัญกับความเข้มงวดในการประเมินผลแบบจำลอง ผ่านดัชนีชี้วัดทางสถิติที่ครอบคลุม ได้แก่ รากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง (Root Mean Squared Error: RMSE), ค่าเฉลี่ยผิดพลาดกำลังสอง (Mean Squared Error: MSE), ค่าความคลาดเคลื่อนแบบสัมบูรณ์ (Absolute Error: AE), ค่าความคลาดเคลื่อนยกกำลังสอง (Squared Error: SE) และ ค่าสัมประสิทธิ์การตัดสินใจพหุคูณ (R -Squared: R^2) เพื่อวัดประสิทธิภาพและความแม่นยำของแต่ละเทคนิคในการพยากรณ์การเติบโตของตลาดรถยนต์ไฟฟ้า งานวิจัยนี้ใช้วิธีการแบ่งข้อมูลเพื่อการทดสอบแบบ 10-fold cross-validation ร่วมกับการทดลองซ้ำด้วยการกำหนดค่าสุ่มเริ่มต้น (Random Seed) จำนวน 30 ครั้ง เพื่อให้ได้ค่าเฉลี่ยของเกณฑ์การประเมินที่น่าเชื่อถือที่สุด [7] ผลลัพธ์จากการศึกษานี้มุ่งหวังที่จะช่วยเติมเต็มช่องว่างทางวิชาการด้านการพยากรณ์ตลาดยานยนต์ไฟฟ้าในบริบทของประเทศไทย และสนับสนุนกระบวนการตัดสินใจที่ขับเคลื่อนด้วยข้อมูล (Data-Driven

Decision Making) สำหรับผู้กำหนดนโยบายและภาคธุรกิจ เพื่อส่งเสริมการเปลี่ยนผ่านของประเทศไทยสู่เศรษฐกิจสีเขียวและระบบขนส่งที่ยั่งยืนในอนาคต [5,8]

2. วัตถุประสงค์

2.1 เพื่อสร้างตัวแบบจำลองสำหรับการพยากรณ์การเติบโตของการใช้รถยนต์ไฟฟ้าในประเทศไทย

2.2 เพื่อประเมินประสิทธิภาพของตัวแบบสำหรับการพยากรณ์การเติบโตของการใช้รถยนต์ไฟฟ้าในประเทศไทย

แนวคิด ทฤษฎี และวรรณกรรมที่เกี่ยวข้อง

ในปัจจุบัน การพัฒนาเทคโนโลยีด้านยานยนต์ไฟฟ้า ได้กลายเป็นหนึ่งในกลยุทธ์สำคัญในการลดการปล่อยก๊าซเรือนกระจกและสนับสนุนเศรษฐกิจสีเขียว ดังนั้น การศึกษาปัจจัยที่ส่งผลต่อการเติบโตของการใช้รถยนต์ไฟฟ้าและการพยากรณ์แนวโน้มในอนาคตจึงมีความสำคัญอย่างยิ่งในการกำหนดทิศทางเชิงนโยบายและการวางแผนธุรกิจที่เกี่ยวข้อง [9]


ในด้านทฤษฎีการวิเคราะห์ข้อมูลเชิงพยากรณ์ โดยเฉพาะเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) เทคนิคการถดถอยเชิงเส้น (Linear Regression) เป็นเครื่องมือที่ใช้ในการศึกษาความสัมพันธ์ระหว่างตัวแปรอิสระและตัวแปรตาม ในลักษณะเชิงเส้นโมเดลพื้นฐานของการถดถอยเชิงเส้นได้จากสูตร (1)

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon \quad (1)$$

ซึ่ง β แทนค่าสัมประสิทธิ์ถดถอย และ ε แทนค่าความคลาดเคลื่อน สามารถตีความค่า coefficient ได้ง่ายและใช้เป็น baseline ในการเปรียบเทียบกับโมเดลอื่น ๆ โมเดลการถดถอยเชิงเส้นสามารถใช้ทำนายค่าของตัวแปรตามจากข้อมูลของตัวแปรอิสระต่าง ๆ ได้ ซึ่งเหมาะสมสำหรับกรณีที่ข้อมูลมีลักษณะเป็นเชิงเส้น [10]

ในงานวิจัยที่ศึกษาเกี่ยวกับการพยากรณ์การใช้พลังงานของรถยนต์ไฟฟ้า เทคนิคโครงข่ายประสาทเทียม (Neural Network: NN) ดังภาพที่ 1 ได้ถูกนำมาใช้เพื่อจับความสัมพันธ์ที่ไม่เป็นเชิงเส้นระหว่างข้อมูลที่มีความซับซ้อนและหลายมิติ [11] เทคนิคโครงข่ายประสาทเทียม มีประสิทธิภาพในการพยากรณ์ได้ดีกว่าเทคนิคการถดถอยเชิงเส้น โดยมีค่าสัมประสิทธิ์การตัดสินใจ


พหุคูณ และรากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง ที่ดีขึ้นเมื่อเปรียบเทียบกับตัวแบบจำลองอื่นๆ ซึ่งแสดงให้เห็นถึงความสามารถของโครงข่ายประสาทเทียม ในการจับความสัมพันธ์ที่ไม่เป็นเชิงเส้นได้แม่นยำมากขึ้นในข้อมูลที่มีความซับซ้อนและหลายมิติ [12]



ภาพ 1 การทำงานของเทคนิคโครงข่ายประสาทเทียม

ที่มา: ผู้วิจัย

เทคนิคการเรียนรู้เชิงลึก (Deep Learning) เป็นการขยายแนวคิดของโครงข่ายประสาทเทียมให้สามารถมีหลายชั้นซ่อน (Hidden Layers) ดังภาพที่ 2 ที่ช่วยให้สามารถเรียนรู้คุณลักษณะที่ซับซ้อนได้ดีขึ้น โดยเฉพาะในงานพยากรณ์เชิงเวลา เช่น การพยากรณ์ยอดขายรถยนต์ไฟฟ้า โดยเฉพาะโมเดลโครงข่ายประสาทเทียมแบบจำระยะยาว-สั้น (Long Short-Term Memory: LSTM) และโมเดลโครงข่ายประสาทเทียมแบบ Convolutional (Convolutional Neural Network: CNN) ซึ่งนิยมใช้ในงานที่ต้องจับแนวโน้มเชิงเวลา [13] โมเดลเหล่านี้สามารถทำนายแนวโน้มตลาดได้แม่นยำและมีประสิทธิภาพสูงเมื่อเทียบกับเทคนิคการเรียนรู้ของเครื่องอื่นๆ



ภาพ 2 การทำงานของเทคนิคการเรียนรู้เชิงลึก

ที่มา: ผู้วิจัย

งานวิจัยที่เกี่ยวข้องในอดีตได้ศึกษาปัจจัยที่มีอิทธิพลต่อการเติบโตของการใช้รถยนต์ไฟฟ้าในหลายประเทศ เช่น งานที่ศึกษา

ความสัมพันธ์ระหว่างปัจจัยทางเศรษฐกิจ ต่อยอดขายรถยนต์ไฟฟ้าในสหรัฐอเมริกา โดยใช้เทคนิคการถดถอยเชิงเส้นและเทคนิคโครงข่ายประสาทเทียมแบบจำระยะยาว-สั้น เพื่อเปรียบเทียบประสิทธิภาพ ผลการศึกษาพบว่าราคาน้ำมันและรายได้เฉลี่ยต่อหัวมีผลต่อยอดขายรถยนต์ไฟฟ้าอย่างมีนัยสำคัญทางสถิติ [9] ส่วนงานวิจัยที่พัฒนาแบบจำลองเทคนิคการเรียนรู้เชิงลึก ผลการศึกษาพบว่าโมเดล EVs-PredNet ซึ่งเป็นการผสมผสานระหว่างเทคนิคโครงข่ายประสาทเทียมแบบ Convolutional และเทคนิคโครงข่ายประสาทเทียมแบบจำระยะยาว-สั้น สามารถให้ค่าความแม่นยำสูงกว่าแบบจำลองเชิงเส้น และเทคนิคโครงข่ายประสาทเทียมแบบพื้นฐาน (Artificial Neural Network) โดยมีค่าสัมประสิทธิ์การตัดสินใจพหุคูณ และค่ารากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง ต่ำกว่าโมเดลอื่นอย่างมีนัยสำคัญ แสดงให้เห็นว่าแนวทางของเทคนิคการเรียนรู้เชิงลึก มีศักยภาพสูงในการจับแนวโน้มตลาดรถยนต์ไฟฟ้าในระยะยาว [4]

ในการศึกษาอื่นๆ ผู้วิจัยได้ใช้แบบจำลอง Multiple Linear Regression ร่วมกับการแปลงข้อมูลแบบลอการิทึม (log transformation) เพื่อวิเคราะห์ปัจจัยทางเศรษฐกิจที่มีผลต่อยอดขายและจำนวนรถยนต์ไฟฟ้า โดยพบว่าตัวแปรทางเศรษฐกิจ เช่น รายได้เฉลี่ยของประชากรและจำนวนรถยนต์ไฟฟ้าที่มีอยู่แล้วในตลาด (EV stock) มีความสัมพันธ์เชิงบวกกับยอดขายรถยนต์ไฟฟ้าอย่างมีนัยสำคัญ [14] ซึ่งสะท้อนให้เห็นถึงบทบาทของปัจจัยทางเศรษฐกิจในการขับเคลื่อนการเติบโตของตลาดยานยนต์ไฟฟ้าอย่างต่อเนื่อง

3. วิธีการดำเนินการ

วิธีการดำเนินงานวิจัยโดยทำการสร้างตัวแบบ และทดสอบประสิทธิภาพของตัวแบบพยากรณ์แนวโน้มการเติบโตรถยนต์ไฟฟ้าในอนาคต โดยอาศัยข้อมูลจริงจากกรมการขนส่งทางบก และหน่วยงานภาครัฐที่เกี่ยวข้อง ระหว่างปี พ.ศ. 2563 ถึง 2568 ข้อมูลที่นำมาวิเคราะห์ประกอบด้วยตัวแปรด้านเศรษฐกิจ สังคม และสิ่งแวดล้อม ได้แก่ จำนวนการจดทะเบียนรถยนต์ไฟฟ้า ราคาน้ำมัน ดัชนีความเชื่อมั่นผู้บริโภค ปริมาณการใช้ไฟฟ้าภาคครัวเรือน และจำนวนการเกิดของประชากรไทยทั่วประเทศ เพื่อพัฒนาตัวแบบจำลองการพยากรณ์ด้วยเทคนิคการเรียนรู้ของ

เครื่อง โดยใช้โปรแกรม Altair AI Studio ซึ่งสามารถสร้างและประเมินโมเดลได้โดยอัตโนมัติ ผู้วิจัยได้ดำเนินการโดยอ้างอิงตามกระบวนการมาตรฐานในการทำเหมืองข้อมูล (CRISP-DM) ทั้ง 6 ขั้นตอนหลัก ได้แก่ (1) การทำความเข้าใจเกี่ยวกับปัญหา (Problem Understanding) (2) การทำความเข้าใจเกี่ยวกับข้อมูล (Data Understanding) (3) การเตรียมข้อมูล (Data Preparation) (4) การสร้างแบบจำลอง (Modeling) (5) การประเมินผล (Evaluation) และ (6) การนำเอาแบบจำลองไปใช้งาน (Deployment) ได้อธิบายกรอบแนวคิดการวิจัย [7]

3.1 การทำความเข้าใจเกี่ยวกับปัญหา (Problem Understanding)

ปัญหาหลักของการศึกษานี้คือการเติบโตของตลาดรถยนต์ไฟฟ้าที่มีความผันผวนตามปัจจัยทางเศรษฐกิจและนโยบายภาครัฐ เช่น ราคาน้ำมัน การสนับสนุนจากภาครัฐ และดัชนีความเชื่อมั่นผู้บริโภค ซึ่งล้วนส่งผลโดยตรงต่อการตัดสินใจของผู้บริโภค งานวิจัยนี้จึงมุ่งเน้นการวิเคราะห์ปัจจัยที่มีอิทธิพลต่อยอดการจดทะเบียนรถยนต์ไฟฟ้า และสร้างแบบจำลองเพื่อพยากรณ์แนวโน้มการเติบโตของรถยนต์ไฟฟ้าในอนาคต เพื่อใช้เป็นแนวทางเชิงนโยบายในการส่งเสริมอุตสาหกรรมยานยนต์ไฟฟ้าและการลดการปล่อยคาร์บอนในระยะยาว [12]

3.2 การทำความเข้าใจเกี่ยวกับข้อมูล (Data Understanding)

ผู้วิจัยได้รวบรวมข้อมูลทุติยภูมิที่เกี่ยวข้องกับปัจจัยที่ส่งผลต่อการเติบโตของรถไฟฟ้า จากวันที่ 1 มกราคม 2563 ถึงวันที่ 31 ธันวาคม 2567 และได้รวบรวมข้อมูลการจดทะเบียนรถยนต์ไฟฟ้าในประเทศไทยจากฐานข้อมูลของกรมการขนส่งทางบก [1] เว็บไซต์ Investing.com [15] และข้อมูลสนับสนุนจากหน่วยงานภาครัฐ อย่างเว็บไซต์กระทรวงพลังงาน [16] เว็บไซต์กรมการปกครอง กระทรวงมหาดไทย [17] โดยเก็บข้อมูลเป็นรายเดือนครอบคลุมช่วงปี.ศ. 2563 ถึง 2567 จำนวนทั้งหมด 5 ปี หรือจำนวนทั้งสิ้น 60 เดือน และถูกจัดเก็บในรูปแบบไฟล์ .csv เพื่อนำไปใช้ในการวิเคราะห์ต่อไป

3.3 การเตรียมข้อมูล (Data Preparation)

3.3.1 การคัดเลือกข้อมูล (Data Selection) ในการคัดเลือกข้อมูลที่เหมาะสมสำหรับการวิเคราะห์ โดยข้อมูลที่จำเป็นในการวิเคราะห์ในครั้งนี้ มีตัวแปรทั้งหมด 4 แอตทริบิวต์ ได้แก่ (1) ค่าใช้จ่ายไฟฟ้าภาคครัวเรือนเฉลี่ยรายเดือน (บาท รวมค่า Ft) (2)

ราคาน้ำมันเฉลี่ยรายเดือน (บาท/ลิตร) (3) และจำนวนการเกิดของประชากรไทยทั่วประเทศแบบรายเดือน (4) ดัชนีความเชื่อมั่นผู้บริโภค ข้อมูลช่วงเวลาที่ใช้ระบุการเปลี่ยนแปลงรายเดือน

3.3.2 การกำหนดหน้าที่ของตัวแปร เพื่อนำไปใช้สำหรับการวิเคราะห์โดยกำหนดแอตทริบิวต์ จำนวนการจดทะเบียนรถยนต์ไฟฟ้า (EV_Registrations) ทำหน้าที่เป็นตัวแปรตาม (Label) ที่ใช้ในการพยากรณ์ในครั้งนี้ และแอตทริบิวต์อื่นๆ ให้ทำหน้าที่เป็นตัวแปรอิสระ ดังตาราง 1

3.3.3 เพื่อให้ข้อมูลมีคุณภาพเหมาะสมต่อการวิเคราะห์ จึงได้ดำเนินการตรวจสอบค่าที่สูญหาย (Missing Values) และค่าผิดปกติ (Outliers) ในเบื้องต้น ผลการตรวจสอบพบว่า ข้อมูลไม่มีค่าที่ขาดหายและไม่พบ Outliers ที่ส่งผลกระทบต่อ การวิเคราะห์ จึงสามารถนำข้อมูลเข้าสู่กระบวนการวิเคราะห์ได้ทันที

ตาราง 1 ข้อมูลแอตทริบิวต์ปัจจัยที่มีผลต่อการเติบโตของรถยนต์ไฟฟ้า

ลำดับ	Attributes	รายละเอียด	Data Type	ตัวอย่างข้อมูลที่จัดเก็บ
1	EV_Registrations	ยอดจดทะเบียนรถยนต์ไฟฟ้า	Integer	1224
2	Month	เดือน	Integer	1
3	Year	ปี	Integer	2020
4	Oil Price	ราคาน้ำมัน (Baht)	Real	41.15
5	Births_Total	จำนวนประชากร	Integer	51587
6	Total Electricity Cost and Ft	ค่าไฟฟ้าต่อหน่วย	Real	3.64
7	Consumer_Confidence_Index	ดัชนีความเชื่อมั่นผู้บริโภค	Real	67.3

3.4 การสร้างแบบจำลอง (Modeling)

ในการวิเคราะห์ ผู้วิจัยได้ทำการขั้นตอนการสร้างแบบจำลอง (Modeling Process) โดยใช้ เทคนิคการเรียนรู้ของเครื่อง 3 เทคนิค ได้แก่ เทคนิคการถดถอยเชิงเส้น เทคนิคโครงข่ายประสาทเทียม และเทคนิคการเรียนรู้เชิงลึก โดยกระบวนการนี้เป็นการสร้างตัวแบบและเปรียบเทียบโมเดลหลายเทคนิคเพื่อพยากรณ์การเติบโตของรถยนต์ไฟฟ้า (EV Growth Forecasting) ด้วยโปรแกรม Altair AI Studio [18] สำหรับการกำหนดค่าไฮเปอร์พารามิเตอร์ในกระบวนการสร้างแบบจำลองผ่านโปรแกรม Altair AI Studio ได้รับรายละเอียดเชิงเทคนิคเพื่อให้สามารถทำซ้ำงานวิจัยได้อย่างแม่นยำ โดยในส่วนของ การถดถอยเชิงเส้น ได้เลือกใช้วิธีการคัดเลือกตัวแปรแบบ M5 Prime ควบคู่กับการเปิดฟังก์ชันกำจัดตัวแปรที่มีความสัมพันธ์กันเอง (Eliminate Colinear Features) เพื่อลดความซ้ำซ้อนของข้อมูล โดยกำหนดค่าความคลาดเคลื่อนต่ำสุด (Min Tolerance) ไว้ที่ 0.05 และค่า Ridge ที่ $1.0E-8$ สำหรับแบบจำลอง โครงข่ายประสาทเทียม ได้กำหนด Hidden Layers เท่ากับ 4 ส่วนรอบการเรียนรู้ (Training Cycles) จำนวน 200 รอบ ด้วยอัตราการเรียนรู้ (Learning Rate) ที่ 0.01 และค่าโมเมนตัม (Momentum) เท่ากับ 0.9 โดยมีการเปิดใช้งานฟังก์ชัน Normalize เพื่อปรับข้อมูลให้อยู่ในมาตรฐานเดียวกัน ในขณะที่ เทคนิค การเรียนรู้เชิงลึก ผู้วิจัยเลือกใช้ฟังก์ชันกระตุ้นแบบ Rectifier โดยดำเนินการฝึกสอนข้อมูลจำนวน 10 Epochs ภายใต้การตั้งค่าอัตราการเรียนรู้แบบปรับตัวได้ (Adaptive Rate) ซึ่งกำหนดค่า Epsilon ไว้ที่ $1.0E-8$ และค่า Rho ที่ 0.99 นอกจากนี้ยังมีการกำหนดค่า L1 Regularization ที่ระดับ $1.0E-5$ เพื่อป้องกันปัญหาการเรียนรู้ที่มากเกินไป (Overfitting) ของแบบจำลอง

3.5 การประเมินผล (Evaluation)

ผู้วิจัยได้ทำการตรวจสอบประสิทธิภาพของการประมาณค่าข้อมูล ด้วยวิธี 10-fold cross validation Test แบ่งชุดข้อมูลเป็น 10 ส่วน เพื่อให้การกระจายของข้อมูลเท่าๆ กัน และทำการกำหนด random seed โดยไม่ซ้ำกัน ตั้งแต่ random seed ที่ 2001 ถึง 2030 เป็นจำนวน 30 รอบ เพื่อหาค่าเฉลี่ยของเกณฑ์ที่ใช้วัดประสิทธิภาพของการพยากรณ์ โดยมีเกณฑ์ที่ใช้วัดประสิทธิภาพของการพยากรณ์ค่าสำหรับงานวิจัยนี้ได้แก่ รากที่

สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง, ค่าเฉลี่ยผิดพลาดกำลังสอง, ค่าความคลาดเคลื่อนแบบสัมบูรณ์, ค่าความคลาดเคลื่อนยกกำลังสอง และ สัมประสิทธิ์การตัดสินใจ พหุคูณ [7]

3.5.1 รากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง (Root Mean Squared Error: RMSE) รากที่สองของค่าความคลาดเคลื่อนยกกำลังสองเฉลี่ยเป็นตัวชี้วัดที่ใช้กันอย่างแพร่หลายในปัญหาทางธุรกิจ ซึ่งความคลาดเคลื่อนที่มีขนาดใหญ่ ส่งผลกระทบมากกว่า

3.5.2 ค่าเฉลี่ยผิดพลาดกำลังสอง (Mean Squared Error: MSE) เป็นค่าเฉลี่ยของความผิดพลาดยกกำลังสอง โดยการคำนวณนี้จะคำนึงถึงความผิดพลาดที่มีขนาดใหญ่ เพื่อให้น้ำหนักกับการทำนายที่ผิดพลาดมากขึ้น การมีค่า MSE ที่ต่ำแสดงว่าโมเดลทำนายได้แม่นยำ

3.5.3 ค่าความคลาดเคลื่อนแบบสัมบูรณ์ (Absolute Error: AE) ค่าความผิดพลาดที่วัดได้จากความแตกต่างระหว่างค่าที่ทำนายกับค่าจริง โดยไม่สนใจทิศทางของความผิดพลาด ค่า AE ที่ต่ำแสดงว่าโมเดลทำนายได้ใกล้เคียงกับค่าจริงมากขึ้นในแง่ของความผิดพลาดเฉลี่ยของข้อมูล

3.5.4 ค่าความคลาดเคลื่อนยกกำลังสอง (Squared Error: SE) ค่า SE คำนวณจากการยกกำลังสองของความผิดพลาดในแต่ละจุดข้อมูล ซึ่งจะเพิ่มความหนักของค่าผิดพลาดที่สูงขึ้น การมีค่า SE ที่ต่ำแสดงว่าโมเดลสามารถทำนายข้อมูลได้แม่นยำ โดยเฉพาะข้อมูลที่มีความผิดพลาดน้อย

3.5.5 ค่าสัมประสิทธิ์การตัดสินใจ (Coefficient of Determination: R-Squared: R²) ค่าข้อมูล มีความเหมาะสมกับข้อมูลมากน้อยเพียงใด ซึ่งจะแสดงถึงขอบเขตความสามารถในการคาดการณ์การแปรผันของตัวแปรตามของโมเดล ยกตัวอย่างเช่น หากค่า R² เท่ากับ 1 จะแสดงว่า ตัวแปรต้น (Independent Variable) ในโมเดลสามารถอธิบายการแปรผันทั้งหมดที่สังเกตได้จากตัวแปรตาม (Dependent Variable) และถ้าหากโมเดลมีค่า R² น้อย อาจแปลได้ว่าจะต้องมีการเพิ่มตัวแปรต้น อื่นๆ เข้าไป เพื่อให้โมเดลมีการพยากรณ์ที่แม่นยำมากยิ่งขึ้น

3.6 การนำแบบจำลองไปใช้งาน (Deployment)

โดยผลลัพธ์จากการวิเคราะห์ข้อมูลจะได้ตัวแบบพยากรณ์ที่มีความเหมาะสมสำหรับการพยากรณ์การเติบโตของรถยนต์ไฟฟ้า

สามารถนำไปใช้ในการวางแผนเชิงกลยุทธ์ทั้งในภาครัฐและภาคเอกชน เช่น การขยายโครงสร้างพื้นฐานสถานีชาร์จไฟฟ้า การกำหนดนโยบายสนับสนุนทางภาษี หรือการคาดการณ์ความต้องการตลาดยานยนต์ไฟฟ้าในอนาคต ผลลัพธ์จากการพยากรณ์ยังสามารถนำไปใช้ในการตัดสินใจเชิงนโยบายเพื่อสนับสนุนการพัฒนาอุตสาหกรรมยานยนต์ไฟฟ้าให้เติบโตอย่างยั่งยืน ซึ่งสอดคล้องกับการศึกษาที่ใช้ผลการพยากรณ์ในการคาดการณ์ความต้องการพลังงานของรถยนต์ไฟฟ้าในเมืองบาร์เซโลนา [11] มีผลลัพธ์จากการวิเคราะห์ข้อมูลจะได้ตัวแบบพยากรณ์ที่มีความเหมาะสมสำหรับการพยากรณ์โมเดลสามารถนำไปใช้ในการวางแผนการจัดการพลังงานในเมือง รวมถึงการตัดสินใจเกี่ยวกับการขยายโครงสร้างพื้นฐานและการบริหารจัดการพลังงานในอนาคต

4. ผลการวิจัย

ผู้วิจัยได้ทำการสร้างตัวแบบในการพยากรณ์การเติบโตของรถยนต์ไฟฟ้า โดยใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning Techniques) และมุ่งเน้นการลดอคติจากการสุ่มข้อมูลและเพิ่มความน่าเชื่อถือของผลลัพธ์ด้วยกระบวนการ 10-fold Cross Validation ร่วมกับการกำหนดค่า Random Seed ที่แตกต่างกันในช่วงปี 2001 ถึง 2030 รวมทั้งสิ้น 30 รอบการทดสอบ จึงได้ตารางของเทคนิคการเรียนรู้ของเครื่อง 3 เทคนิค ได้แก่ เทคนิคการถดถอยเชิงเส้น , เทคนิคโครงข่ายประสาทเทียม และเทคนิคการเรียนรู้เชิงลึก เพื่อให้การเปรียบเทียบประสิทธิภาพระหว่างเทคนิคมีความถูกต้องตามหลักสถิติ ผู้วิจัยได้ทำการตรวจสอบข้อตกลงเบื้องต้นด้านความเท่ากันของความแปรปรวน (Homogeneity of Variance) ที่ระดับนัยสำคัญทางสถิติ 0.05 [7] ซึ่งให้ผลลัพธ์ดังตาราง 2

ตาราง 2 ตาราง Tests of Homogeneity of Variances

	Levene			
	Statistic	df1	df2	Sig.
Accuracy	0.216	2	87	0.806

* at 0.05 significant level

ดังตาราง 2 พบว่าค่าสถิติ Levene เท่ากับ 0.216 และค่า Sig. เท่ากับ 0.806 (Sig. > 0.05) ซึ่งมีค่ามากกว่าค่าระดับนัยสำคัญที่กำหนด ผลลัพธ์ดังกล่าวบ่งชี้ว่าความแปรปรวนของค่าความแม่นยำจากทั้ง 3 ตัวแบบไม่มีความแตกต่างกัน ที่ระดับ

นัยสำคัญทางสถิติที่ระดับ 0.05 จึงมีความเหมาะสมในการใช้การวิเคราะห์ความแปรปรวน (ANOVA) เพื่อทดสอบสมมติฐานความแตกต่างของค่าเฉลี่ยความแม่นยำในลำดับต่อไป ดังปรากฏผลลัพธ์ในตาราง 3

ตาราง 3 การวิเคราะห์ความแปรปรวน (ANOVA)

Source of Variable	Sum of Squares	df	Mean Square	F	Sig.
Between Groups	0.013	2	0.006	3.695	0.029
Within Groups	0.148	87	0.002		
Total	0.161	89			

* at 0.05 significant level

พิจารณาผลการทดสอบความแปรปรวนดังแสดงในตาราง 3 พบว่าค่า Sig. เท่ากับ 0.029 (Sig. < 0.05) ซึ่งต่ำกว่าระดับนัยสำคัญทางสถิติที่กำหนดไว้ ผลลัพธ์ดังกล่าวบ่งชี้ว่ามีอย่างน้อย 1 คู่ของเทคนิคการพยากรณ์ที่มีค่าเฉลี่ยความแม่นยำแตกต่างกันอย่างมีนัยสำคัญ ผู้วิจัยจึงได้ทำการทดสอบเปรียบเทียบรายคู่ (Multiple Comparisons) ภายหลังการทดลอง (Post Hoc Test) ด้วยวิธี Bonferroni เพื่อระบุคู่ของเทคนิคที่มีความแตกต่างกันดังตาราง 4

ตาราง 4 ผลการเปรียบเทียบความแตกต่างรายคู่ของค่าเฉลี่ยความแม่นยำ ด้วยวิธี Bonferroni

	Linear Regression	Neural Network	Deep Learning
Linear Regression	-	-0.029*	-0.014
Neural Network		-	0.015
Deep Learning			-

* at 0.05 significant level

จากการวิเคราะห์เปรียบเทียบรายคู่พบว่า เทคนิคโครงข่ายประสาทเทียม และเทคนิคการถดถอยเชิงเส้น มีค่า Sig. เท่ากับ 0.024 (Sig. < 0.05) ซึ่งมีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติที่ระดับ 0.05 โดยเมื่อพิจารณาค่าผลต่างค่าเฉลี่ย (Mean Difference) ร่วมด้วยจะพบว่าโครงข่ายประสาทเทียมให้

ประสิทธิภาพความแม่นยำที่สูงกว่า ในขณะที่เทคนิคการเรียนรู้เชิงลึก ไม่พบความแตกต่างอย่างมีนัยสำคัญ (Sig. > 0.05) เมื่อเทียบกับอีก 2 เทคนิคที่เหลือ ลำดับถัดมาเพื่อให้การประเมินประสิทธิภาพของตัวแบบมีความละเอียดและครอบคลุมมิติความถูกต้องแม่นยำยิ่งขึ้น ผู้วิจัยได้ทำการวิเคราะห์ค่าเฉลี่ยของตัวชี้วัดความคลาดเคลื่อนและประสิทธิภาพการพยากรณ์มาตรฐานประกอบด้วย รากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง ค่าเฉลี่ยผิดพลาดกำลังสอง ค่าความคลาดเคลื่อนแบบสัมบูรณ์ ค่าความคลาดเคลื่อนยกกำลังสอง และสัมประสิทธิ์การตัดสินใจพหุคูณ สำหรับใช้เปรียบเทียบประสิทธิภาพของแต่ละโมเดลได้อย่างเป็นกลางและเชื่อถือได้ [7] ดังตาราง 5

ตาราง 5 การเปรียบเทียบประสิทธิภาพของตัวแบบการประมาณค่าข้อมูลทั้ง 3 เทคนิค

Regression Technique	Regression Performance				
	RMSE	MSE ($\times 10^6$)	AE ($\times 10^3$)	SE ($\times 10^6$)	R ² (%)
Linear regression	1,677.40	2.81	1,257.62	3.18	83%
Neural Net*	1,695.78	2.88	1,246.60	3.65	86%
Deep learning	1,842.58	3.40	1,425.49	4.15	84%

* คือ เทคนิคที่มีความเหมาะสมที่สุดในการพยากรณ์การเติบโตของรถยนต์ไฟฟ้า

จากผลการทดสอบในตาราง 5 พบว่า ตัวแบบที่ใช้ในการพยากรณ์ทั้งสาม ได้แก่ เทคนิคการถดถอยเชิงเส้น, เทคนิคโครงข่ายประสาทเทียม, และเทคนิคการเรียนรู้เชิงลึก มีประสิทธิภาพแตกต่างกัน โดยเมื่อพิจารณาค่าตัวชี้วัดจากการทดสอบทั้งหมด พบว่า เทคนิคโครงข่ายประสาทเทียม มีประสิทธิภาพสูงที่สุดในการพยากรณ์แนวโน้มการเติบโตของการยอมรับรถยนต์ไฟฟ้า โดยผลการคำนวณค่ารากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง แสดงให้เห็นว่าเทคนิคการถดถอยเชิงเส้น มีค่ารากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง ต่ำที่สุดที่ 1,677.40 ซึ่งบ่งชี้ถึงความแม่นยำในการทำนายที่ดีในระดับพื้นฐาน รองลงมาคือเทคนิคโครงข่ายประสาทเทียม มีค่าเท่ากับ 1,695.78 และเทคนิคการเรียนรู้เชิงลึก มีค่าเท่ากับ 1,842.58 และเทคนิคการถดถอยเชิงเส้น ยังมีค่าเฉลี่ยผิดพลาดกำลังสอง น้อยที่สุดที่ 2,813,670.76 รองลงมาคือ

เทคนิคโครงข่ายประสาทเทียม มีค่าเท่ากับ 2,875,669.81 และเทคนิคการเรียนรู้เชิงลึก มีค่าเท่ากับ 3,395,101.06 อย่างไรก็ตาม เมื่อพิจารณาค่าความคลาดเคลื่อนแบบสัมบูรณ์ และค่าสัมประสิทธิ์การตัดสินใจพหุคูณ พบว่า เทคนิคโครงข่ายประสาทเทียม ให้ค่าความคลาดเคลื่อนแบบสัมบูรณ์ ต่ำที่สุดที่ 1,246.60 รองลงมาคือเทคนิคการถดถอยเชิงเส้น มีค่าเท่ากับ 1,257.62 และเทคนิคการเรียนรู้เชิงลึก มีค่าเท่ากับ 1,425.49 ส่วนค่าความคลาดเคลื่อนยกกำลังสอง พบว่าเทคนิคการถดถอยเชิงเส้น มีค่าเท่ากับ 3,182,450.25 ซึ่งต่ำที่สุด รองลงมาคือเทคนิคโครงข่ายประสาทเทียม มีค่าเท่ากับ 3,645,652.02 และเทคนิคการเรียนรู้เชิงลึก มีค่าเท่ากับ 4,147,104.11 ในส่วนของเทคนิคโครงข่ายประสาทเทียม ยังมีค่าสัมประสิทธิ์การตัดสินใจพหุคูณ สูงสุดที่ 86.00% รองลงมาคือเทคนิคการเรียนรู้เชิงลึก มีค่าเท่ากับ 84.00% และเทคนิคการถดถอยเชิงเส้น มีค่าเท่ากับ 83.00%

5. สรุปและอภิปรายผล

การศึกษานี้บรรล่วัตถุประสงค์ประการแรกในการพัฒนาตัวแบบจำลองทางคณิตศาสตร์เพื่อพยากรณ์การเติบโตของยานยนต์ไฟฟ้าในประเทศไทย โดยดำเนินการผ่านกระบวนการวิเคราะห์ฐานข้อมูลทุติยภูมิรายเดือนที่ครอบคลุมช่วงเวลาตั้งแต่วันที่ 1 มกราคม 2563 ถึง 31 ธันวาคม 2567 ผ่านการวิเคราะห์เปรียบเทียบประสิทธิภาพของ 3 เทคนิคหลัก ได้แก่ การถดถอยเชิงเส้น, โครงข่ายประสาทเทียม และการเรียนรู้เชิงลึก ซึ่งนำไปสู่การตอบสนองวัตถุประสงค์ประการที่สองในการประเมินประสิทธิภาพของตัวแบบผ่านดัชนีชี้วัดทางสถิติที่สำคัญ ประกอบด้วย รากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง, ค่าเฉลี่ยผิดพลาดกำลังสอง, ค่าความคลาดเคลื่อนแบบสัมบูรณ์, ค่าความคลาดเคลื่อนยกกำลังสอง และ สัมประสิทธิ์การตัดสินใจพหุคูณ โดยผลการวิเคราะห์ข้อมูลแสดงให้เห็นถึงความแตกต่างอย่างมีนัยสำคัญระหว่างเทคนิคต่างๆ แม้ว่าเทคนิคการถดถอยเชิงเส้น จะให้ค่ารากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง ต่ำที่สุดที่ 1,246.60 ซึ่งสะท้อนถึงความแม่นยำในระดับพื้นฐานที่ดี [19] แต่เมื่อพิจารณาในมิติของความสามารถในการอธิบายความแปรปรวนของข้อมูลและความคลาดเคลื่อนสัมบูรณ์ พบว่าเทคนิคโครงข่ายประสาทเทียม มี

ประสิทธิภาพที่เหนือกว่าอย่างชัดเจน โดยมีค่าความคลาดเคลื่อนแบบสัมบูรณ์ ต่ำที่สุดที่ 1,246.60 และมีค่าสัมประสิทธิ์การตัดสินใจ สูงสุดถึงร้อยละ 86.00 ซึ่งบ่งชี้ว่าตัวแบบนี้สามารถทำนายผลได้ใกล้เคียงกับข้อมูลจริงและอธิบายพลวัตของข้อมูลได้ดีกว่าเทคนิคอื่นๆ [19] ในขณะที่เทคนิคการเรียนรู้เชิงลึกกลับแสดงค่ารากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง สูงที่สุดที่ 1,425.49 และค่าเฉลี่ยผิดพลาดกำลังสอง สูงถึง 3,395,101.06 แม้จะมีค่าสัมประสิทธิ์การตัดสินใจพหุคูณ อยู่ที่ร้อยละ 84.00 แต่ระดับความคลาดเคลื่อนที่สูงสะท้อนให้เห็นว่าจากการเปรียบเทียบประสิทธิภาพ พบว่าเทคนิคการเรียนรู้เชิงลึก มีค่ารากที่สองค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง และ ค่าเฉลี่ยผิดพลาดกำลังสอง สูงกว่าเทคนิคอื่น ๆ สาเหตุหลักคาดว่าเกิดจากข้อจำกัดของขนาดชุดข้อมูลที่มีเพียง 60 เดือน ซึ่งอาจไม่เพียงพอสำหรับโมเดลที่มีความซับซ้อนสูง ส่งผลให้เกิดภาวะ Overfitting ในขณะที่โมเดลที่มีความซับซ้อนน้อยกว่าอย่างเทคนิคการถดถอยเชิงเส้น และเทคนิคโครงข่ายประสาทเทียม สามารถเรียนรู้รูปแบบข้อมูลได้ดีกว่าภายใต้ข้อจำกัดนี้

ผลการทดสอบทั้งหมดสรุปได้ว่า เทคนิคโครงข่ายประสาทเทียมเป็นเครื่องมือที่เหมาะสมที่สุดสำหรับการพยากรณ์ในบริบทนี้ เนื่องจากงานวิจัยนี้ให้ความสำคัญกับค่าสัมประสิทธิ์การตัดสินใจพหุคูณ และ ค่าเฉลี่ยผิดพลาดกำลังสอง เพื่อเน้นการพยากรณ์แนวโน้มภาพรวมมากกว่าค่าเฉพาะจุด ข้อค้นพบนี้สอดคล้องกับงานวิจัยในอดีต [11] ที่ระบุว่าโครงข่ายประสาทเทียมมีความแม่นยำสูงกว่าการถดถอยเชิงเส้นในการพยากรณ์การใช้พลังงาน และมีความสามารถที่โดดเด่นในการจัดรูปแบบความสัมพันธ์ที่ซับซ้อนและไม่เป็นเชิงเส้นระหว่างปัจจัยทางเศรษฐกิจและสังคม [12]

จากผลสัมฤทธิ์ของตัวแบบข้างต้น นำไปสู่การเสนอแนะแนวทางเชิงนโยบายและการลงทุน โดยความแม่นยำของตัวแบบโครงข่ายประสาทเทียม ($R^2 = 0.86$) สามารถนำไปประยุกต์เป็นเครื่องมือสนับสนุนการตัดสินใจสำหรับภาครัฐและเอกชนในการวางแผนขยายสถานีอัดประจุไฟฟ้าให้สอดคล้องกับจำนวนรถยนต์ไฟฟ้าที่คาดว่าจะเพิ่มขึ้น รวมถึงการออกมาตรการทางภาษีเพื่อกระตุ้นผู้บริโภคในช่วงเวลาที่ผลพยากรณ์ชี้ว่าอัตราการเติบโตอาจชะลอตัว และการขับเคลื่อนนโยบายพลังงานสะอาดของประเทศต่อไป

6. ข้อเสนอแนะ

6.1 ข้อเสนอแนะในการวิจัยครั้งนี้ ข้อเสนอแนะจากการศึกษาครั้งนี้มุ่งเน้นให้มีการปรับปรุงกระบวนการวิเคราะห์และการสร้างแบบจำลองเพื่อเพิ่มความแม่นยำของผลการพยากรณ์ โดยเฉพาะในส่วนของการเตรียมข้อมูลและการเลือกตัวแปรอิสระที่มีผลต่อการยอมรับรถยนต์ไฟฟ้า ซึ่งหากสามารถเพิ่มความละเอียดของข้อมูลเชิงเวลาและปัจจัยทางเศรษฐกิจได้ จะช่วยให้โมเดลมีความเสถียรและสะท้อนแนวโน้มการเติบโตได้ชัดเจนยิ่งขึ้น

6.2 ข้อเสนอแนะในการวิจัยครั้งต่อไป สำหรับการวิจัยในอนาคต ผู้วิจัยขอเสนอแนวทางการพัฒนาแบบจำลองลูกผสม (Hybrid Models) ที่มีความซับซ้อนมากขึ้นเพื่อยกระดับประสิทธิภาพการพยากรณ์ โดยเฉพาะการบูรณาการแบบจำลอง CNN-LSTM ซึ่งใช้ Convolutional Neural Networks (CNN) ทำหน้าที่สกัดคุณลักษณะสำคัญ (Feature Extraction) และจับรูปแบบท้องถิ่น (Local patterns) จากข้อมูลปัจจัยทางเศรษฐกิจและสังคมที่มีหลายมิติ จากนั้นจึงส่งต่อผลลัพธ์ให้ Long Short-Term Memory (LSTM) ซึ่งมีคุณสมบัติโดดเด่นในการจับความสัมพันธ์เชิงเวลาและความต่อเนื่องของข้อมูลในระยะยาว (Long-term temporal dependencies) [20] เพื่อวิเคราะห์แนวโน้มการจดทะเบียนรถยนต์ไฟฟ้าที่เป็นข้อมูลอนุกรมเวลา การประยุกต์ใช้โครงสร้างลูกผสมนี้ เช่น แบบจำลอง EVs-PredNet ได้รับการพิสูจน์ในงานวิจัยที่เกี่ยวข้องว่าสามารถให้ค่าความแม่นยำและค่าความคลาดเคลื่อนที่ต่ำกว่าแบบจำลองเชิงเส้นหรือโครงข่ายประสาทเทียมพื้นฐานอย่างมีนัยสำคัญ นอกจากนี้ การใช้ CNN-LSTM ยังช่วยให้แบบจำลองมีความเสถียรและสามารถจัดการกับข้อมูลที่มีความไม่เป็นเชิงเส้น (Non-linear) และมีความผันผวนสูงได้ดียิ่งขึ้น แนวทางดังกล่าวจะช่วยให้การพยากรณ์ตลาดรถยนต์ไฟฟ้าในประเทศไทยมีความแม่นยำครอบคลุมทั้งมิติเชิงพื้นที่และมิติเชิงเวลา ซึ่งเป็นประโยชน์อย่างยิ่งต่อการวางแผนเชิงยุทธศาสตร์และการตัดสินใจเชิงนโยบายที่ขับเคลื่อนด้วยข้อมูลอย่างแท้จริง [13, 20]

คำชี้แจงการใช้ AI

บทความวิจัยนี้มีเนื้อหาที่สร้างขึ้นหรือได้รับการสนับสนุนจากเครื่องมือปัญญาประดิษฐ์ (AI) ได้แก่ ChatGPT, Gemini ซึ่งถูกนำมาใช้เพื่อช่วยในการดำเนินงาน เช่น การแก้ไขภาษา การสรุปวรรณกรรม ทั้งนี้ ผู้เขียนได้ตรวจสอบเนื้อหาที่สร้างโดย AI อย่าง

รอบคอบ เพื่อให้มั่นใจในความถูกต้อง ความเป็นต้นฉบับ และการปฏิบัติตามหลักจริยธรรมทางวิชาการ ผู้วิจัยขอยืนยันว่า การใช้ AI ไม่ได้ส่งผลกระทบต่อความถูกต้องของกระบวนการวิจัย และองค์ความรู้ทั้งหมดในบทความยังคงเป็นความรับผิดชอบของผู้เขียนแต่เพียงผู้เดียว

เอกสารอ้างอิง

- [1] กรมการขนส่งทางบก. จำนวนรถยนต์ไฟฟ้าที่จดทะเบียนในประเทศไทย. [ออนไลน์] 2567. [สืบค้นวันที่ 16 ตุลาคม 2568]. จาก <https://web.dlt.go.th/statistics/>
- [2] Krungsri Research. แนวโน้มธุรกิจ/อุตสาหกรรม ปี 2567-2569: อุตสาหกรรมรถยนต์ไฟฟ้า. [ออนไลน์] 2567. [สืบค้นวันที่ 11 ตุลาคม 2568]. จาก <https://www.krungsri.com/th/research/industry/industry-outlook/hi-tech-industries/electricvehicle/io/electric-vehicle-2024>
- [3] กระทรวงพลังงาน. [ออนไลน์] 2567. [สืบค้นวันที่ 14 ตุลาคม 2568]. จาก <https://www.energy.go.th/th>
- [4] M. Simsek, M. Karakoç, and M. Arslan, "Deep learning forecasting model for market demand of electric vehicles," *Applied Sciences*, vol. 14, no. 23, p. 10974, 2024.
- [5] Y. Zhang, L. Liu, Y. Zhang, and L. Li, "Machine learning methods for weather forecasting: A survey," *Atmosphere*, vol. 16, no. 1, p. 82, 2025.
- [6] A. Kamis and P. S. Abraham, "Predictive models of electric vehicle adoption in the United States: Charging ahead with renewable energy," *Transportation Research Interdisciplinary Perspectives*, vol. 24, p. 101041, 2024.
- [7] อนุพงศ์ สุขประเสริฐ, อรอนันท์ สำนวณ, และ อุบลวรรณ วิเศษรัตน์. "การพัฒนาและเปรียบเทียบตัวแบบการพยากรณ์เบี้ยประกันภัยรวบรวมของบริษัทประกันชีวิตในประเทศไทยโดยใช้เทคนิคการทำเหมืองข้อมูล". *วารสารคอมพิวเตอร์และเทคโนโลยีสร้างสรรค์*, 2568, หน้า 143 ถึง 155.

- [8] S. Limpasirisuwan, T. Champahom, S. Jomnonkwao, and V. Ratanavaraha, "Promoting sustainable transportation: Factors influencing battery electric vehicle adoption across age groups in Thailand," *Sustainability*, vol. 16, no. 21, p. 9273, 2024.
- [9] S. Afandizadeh, D. Sharifi, N. Kalantari, and H. Mirzahosseini, "Using machine learning methods to predict electric vehicle penetration in the automotive market," *Scientific Reports*, vol. 13, no. 1, p. 8345, 2023.
- [10] H. Atici, A. Bal, and A. O. Aktas, "Forecasting Electric Vehicle Adoption in the USA Using Machine Learning Models," *International Journal of Forecasting*, vol. 39, no. 4, pp. 672-681, 2023.
- [11] M. O. Oyedepi, M. AlDhaifallah, H. Rezk, and A. A. A. Mohamed, "Computational models for forecasting electric vehicle energy demand," *International Journal of Energy Research*, vol. 47, no. 3, p. 1934188, 2023.
- [12] S. Fu and H. Fu, "A method to predict electric vehicles' market penetration as well as its impact on energy saving and CO₂ mitigation," *Energy Exploration & Exploitation*, vol. 39, no. 6, pp. 1773-1791, 2021.
- [13] P. Mishra, R. P. Singh, and A. K. Singh, "Hybrid LSTM-GBRT Based Machine Learning Technique for EV Sales Prediction," *Journal of Intelligent Systems*, vol. 33, no. 4, pp. 451-462, 2024.
- [14] "Analysis of Factors Influencing Electric Vehicle Sales," in *Proceedings of the 14th International Conference on Applied Economics and Business*, SCITEPRESS – Science and Technology Publications, 2025.
- [15] Investing. com. Thai Consumer Confidence. [ออนไลน์] 2567. [สืบค้นวันที่ 14 ตุลาคม 2568]. จาก <https://th.investing.com/economic-calendar/thai-consumer-confidence-803>
- [16] Justpow. ข้อมูลค่าไฟฟ้าต่อหน่วย (Total Electricity Cost and Ft). [ออนไลน์] 2567. [สืบค้นวันที่ 14 ตุลาคม 2568]. จาก <https://justpow.co/database-electricity-tariffs-2525-2567/>
- [17] สำนักบริหารการทะเบียน, กรมการปกครอง. สถิติประชากรทางการทะเบียนราษฎร (รายเดือน). [ออนไลน์] 2567. [สืบค้นวันที่ 14 ตุลาคม 2568]. จาก <https://stat.bora.dopa.go.th/stat/statnew/statMONTH/statmonth/#/mainpage>
- [18] อนพงค์ สุขประเสริฐ, การทำเหมืองข้อมูลด้วยโปรแกรม Altair Al Studio. คณะการบัญชีและการจัดการมหาวิทยาลัยมหาสารคาม. 2568.
- [19] R. J. Hyndman. "What's the difference between MAE and RMSE?." [Online]. 2020. [Accessed: Oct. 14, 2025]. Available:<https://robjhyndman.com/hyndsight/mae-and-rmse/>
- [20] B. Li and Y. Qian, "Weather prediction using CNN-LSTM for time series analysis: A case study on Delhi temperature data," *Applied and Computational Engineering*, vol. 92, pp. 121-127, 2024.